

Explicación Procesamiento de Datos

- 1) Se comienza leyendo los dataframe con Pandas
- 2) Se eliminan las filas de duplicados de los 4 dataframe que se tienen
- 3) Se exploran los dataframe con funciones integradas de Pandas como df.info()
- 4) Con el uso de las funciones noto que los campos “REDES_SOCIALES” y “SITIOS_WEB” del dataframe de parlamentarios tienen valores nulos en todas las filas, por lo que decido eliminar estas columnas, al considerar que no entregan información y solo ocupan espacio en el computador
- 5) Posteriormente utilizo una función llamada limpiar_texto(text) para limpiar el texto de las columnas TEXTO_PRINCIPAL de los distintos dataframe de participación, enfocandome en eliminar la información innecesaria para el modelo que se va a usar (keyBERT), como lo son los saltos de línea o las mayúsculas.
- 6) Después por todas los dataframe de participación, elimino todas las filas o tuplas que tengan en el campo “TEXTO_PRINCIPAL” un número de caracteres menor a 80, ya que, no permiten obtener información importante. Bien parecido a lo que se hizo en la ayudantía para esta tarea
- 7) Usando una versión de modelo multilenguaje sobre KeyBert, extraigo las palabras clave para todos los dataframe de participación sobre la columna “TEXTO_PRINCIPAL”, procurando dentro de la función de extracción que la relevancia de la keyword dentro del texto sea mayor a 50% y así no considerar palabras que no sean importantes para este mismo

- 8) Posteriormente uso un modelo nltk para sacar todas las palabras keyword que podrían ser sinónimos.
- 9) Finalmente guardo los dataframe dentro de archivos csv que se cargaran dentro de BigQuery